Administración de las Tecnologías de Información

Curso:

Inteligencia de Negocios

Profesor:

Michael Sánchez Soto

Estudiantes:

Daniela Madrigal Sanabria

Eduardo Fernández Cerdas

Marianny Miranda Mojica

Juan Diego Quirós Gómez

Vidal Mesén Rivas

Fecha

21 de Abril, 2026

I Semestre

Tabla de contenido

Descripción General del Caso 4
Objetivos del Proyecto 4
Objetivo General 4
Objetivos Específicos 4
Herramientas Seleccionadas 5
Apache NiFi 5
SQL 5
Metabase 5
Diseño Modelo Transaccional 5
Diseño Modelo Dimensional 7
Diccionario de Datos 8
Diseño ETL 11
Reglas de Limpieza 12
Reglas de Transformación 13
Reglas de Carga 14
Cuadro de Mapeo de Datos (Origen y Destino) 15
dim_estudiante: 15
dim_curso: 15
dim_docente: 16
dim_sede: 16
dim_grupo_oferta: 16
fact_rendimiento: 17
Capturas ETL 18
Capturas del Staging (Origen) 18
Capturas del Flow en Apache NiFi 20
Capturas del DW Destino (PostgreSQL) 22
Decisiones de Diseño ETL y Lecciones Aprendidas 24
Decisiones tomadas 24
Limitaciones del dataset: 24
Limpieza y Validación de datos sintéticos: 24
Observaciones Adicionales de Calidad de Datos: 25
Validación de la solución analítica 26
Métricas Globales del Período 26
Rendimiento por Grupo y Curso 26

Rendimiento por cohorte 26
Análisis por Modalidad y Franja Horaria 27
Diccionario de Correcciones ETL 27
Capturas Dashboard 28
Hallazgos Principales: 30
Hallazgo 1: La tasa de aprobación global es baja (59.5%) 30
Hallazgo 2: La deserción afecta desproporcionadamente a estudiantes de primer ingreso 30
Hallazgo 3: La modalidad virtual nocturna concentra el menor rendimiento 30
Hallazgo 4: La modalidad híbrida en horario tarde presenta el mejor resultado 30
Hallazgo 5: Polarización de rendimiento en cohortes recientes 30
Respuestas a las preguntas de negocio 30
Indicador Adicional Propuesto: Índice de Permanencia por Cohorte (IPC) 31
Limitaciones 32
Conclusiones 32
Recomendaciones 32
Referencias 34

Descripción General del Caso

La institución analizada corresponde a una organización universitaria que ofrece programas académicos en diversas áreas del conocimiento, con presencia en múltiples sedes y modalidades de enseñanza (presencial, virtual o híbrida). En el contexto actual, la universidad enfrenta la necesidad de mejorar la toma de decisiones académicas y administrativas mediante el análisis sistemático de la información relacionada con la matrícula estudiantil, el rendimiento académico y la permanencia de los estudiantes.

Uno de los principales retos de la organización es comprender cómo se distribuye la matrícula en sus diferentes carreras, cursos y sedes a lo largo de los periodos académicos, así como identificar patrones en el desempeño estudiantil, tales como tasas de aprobación, reprobación y deserción. Adicionalmente, resulta fundamental detectar perfiles de estudiantes con mayor riesgo académico o probabilidad de abandono, con el fin de implementar estrategias de intervención temprana que favorezcan su permanencia y éxito académico.

La institución también requiere analizar el uso y la eficiencia de sus recursos académicos, incluyendo la asignación de docentes, franjas horarias, modalidades de estudio y campus, con el objetivo de optimizar la oferta educativa y mejorar la experiencia del estudiante.

Ante esta necesidad, se propone el desarrollo de una solución de Inteligencia de Negocios que integre datos provenientes de los procesos académicos y administrativos, permitiendo transformar datos operacionales en información relevante para la toma de decisiones. Esta solución facilitará el análisis multidimensional de la información, apoyando la identificación de tendencias, patrones y oportunidades de mejora dentro de la institución.

El sistema propuesto permitirá responder preguntas clave del negocio relacionadas con la concentración de matrícula, el comportamiento del rendimiento académico, los factores asociados al riesgo estudiantil y la eficiencia en el uso de recursos académicos. Asimismo, se incorporará al menos un indicador adicional que aporte valor analítico, fortaleciendo la capacidad de organización para anticipar problemas y mejorar sus resultados académicos y administrativos.

En síntesis, este proyecto busca proporcionar una visión integral del desempeño académico institucional mediante el uso de herramientas de Inteligencia de Negocios, contribuyendo a una gestión basada en datos y orientada a la mejora continua.

Objetivos del Proyecto

Objetivo General

Diseñar e implementar una solución integral de Inteligencia de Negocios que permita analizar la matrícula, el rendimiento académico y la permanencia estudiantil en una institución universitaria, con el fin de apoyar la toma de decisiones académicas y administrativas basadas en datos.

Objetivos Específicos

- Analizar el comportamiento de la matrícula estudiantil según carreras, cursos, sedes y periodos académicos, identificando tendencias y concentraciones relevantes.
- Evaluar el rendimiento académico de los estudiantes mediante el análisis de tasas de aprobación, reprobación y deserción, considerando variables como curso, docente y cohorte.
- Identificar perfiles de estudiantes con mayor riesgo académico o probabilidad de abandono, utilizando variables demográficas, académicas y de comportamiento.
- Analizar la eficiencia en el uso de recursos académicos, incluyendo franjas horarias, modalidades de enseñanza y campus, para determinar patrones de mayor demanda y aprovechamiento.
- Diseñar e implementar un modelo dimensional que permita el análisis multidimensional de la información académica.
- Desarrollar un proceso ETL que integre, limpie y transforme los datos provenientes de la fuente transaccional hacia el modelo dimensional.
- Construir una solución analítica (dashboard o reportes) que permita responder las preguntas de negocio planteadas y visualizar los principales indicadores.

- Proponer al menos un indicador adicional que aporte valor analítico al caso, facilitando la detección de oportunidades de mejora en la gestión académica.
- Generar conclusiones y recomendaciones basadas en los hallazgos obtenidos, orientadas a mejorar la permanencia estudiantil y el desempeño académico.

Herramientas Seleccionadas

Para el desarrollo de la solución de Inteligencia de Negocios se seleccionaron herramientas que permiten cubrir las diferentes etapas del proyectos, desde la integración y transformación de datos hasta su almacenamiento de análisis.

Apache NiFi

Apache NiFi se utilizó como herramienta principal para el diseño e implementación del proceso ETL (Extract, Transform, Load). Esta herramienta permite automatizar el flujo de datos desde la fuente transaccional hacia el modelo dimensional mediante una interfaz visual intuitiva basada en flujos. Entre las principales razones de su selección se encuentran:

- Facilita la integración de datos desde múltiples fuentes.
- Permite aplicar reglas de transformación, limpieza y validación de datos.
- Ofrece trazabilidad y monitoreo en tiempo real del flujo de datos.
- Reduce la complejidad de programación al trabajar con componentes configurables.

Gracias a estas características, Apache NiFi permite garantizar la calidad, consistencia y disponibilidad de los datos en el proceso de carga hacia el sistema analítico.

SQL

El lenguaje SQL se empleó para la creación, manipulación y consulta de las bases de datos tanto en la capa transaccional como en el modelo dimensional. Su uso incluye:

- Definición de estructuras de datos (tablas, relaciones, llaves primarias y foráneas).
- Implementación del modelo dimensional (tablas de hechos y dimensiones).
- Ejecución de consultas para validación y análisis de datos.
- Apoyo en procesos de transformación dentro del ETL.

SQL fue seleccionado debido a su estándar ampliamente aceptado, su eficiencia en el manejo de grandes volúmenes de datos y su integración con herramientas de análisis.

Metabase

Metabase se utilizó como herramienta de visualización y análisis de datos, permitiendo la construcción de dashboards interactivos y reportes orientados a responder las preguntas de negocio planteadas. Las principales ventajas de Metabase son:

- Interfaz amigable para la creación de visualizaciones sin necesidad de programación avanzada.
- Capacidad de conexión directa con bases de datos SQL.
- Generación de dashboards dinámicos e interactivos.
- Facilidad para compartir resultados y hallazgos con usuarios no técnicos.

Mediante el uso de Metabase, se logra presentar la información de forma clara y accesible, facilitando la interpretación de los datos y apoyando la toma de decisiones dentro de la institución.

Diseño Modelo Transaccional

El modelo transaccional de este proyecto está diseñado bajo una estructura relacional normalizada con la capacidad de capturar datos académicos e información institucional, la arquitectura se centra en una tabla principal de Matrícula, la cual actúa como el centro del sistema al vincular a los estudiantes con sus respectivos grupos, cursos y docentes en un periodo académico específico. Esta estructura permite registrar eventos como el rendimiento académico y el estado final del curso (aprobación o deserción).

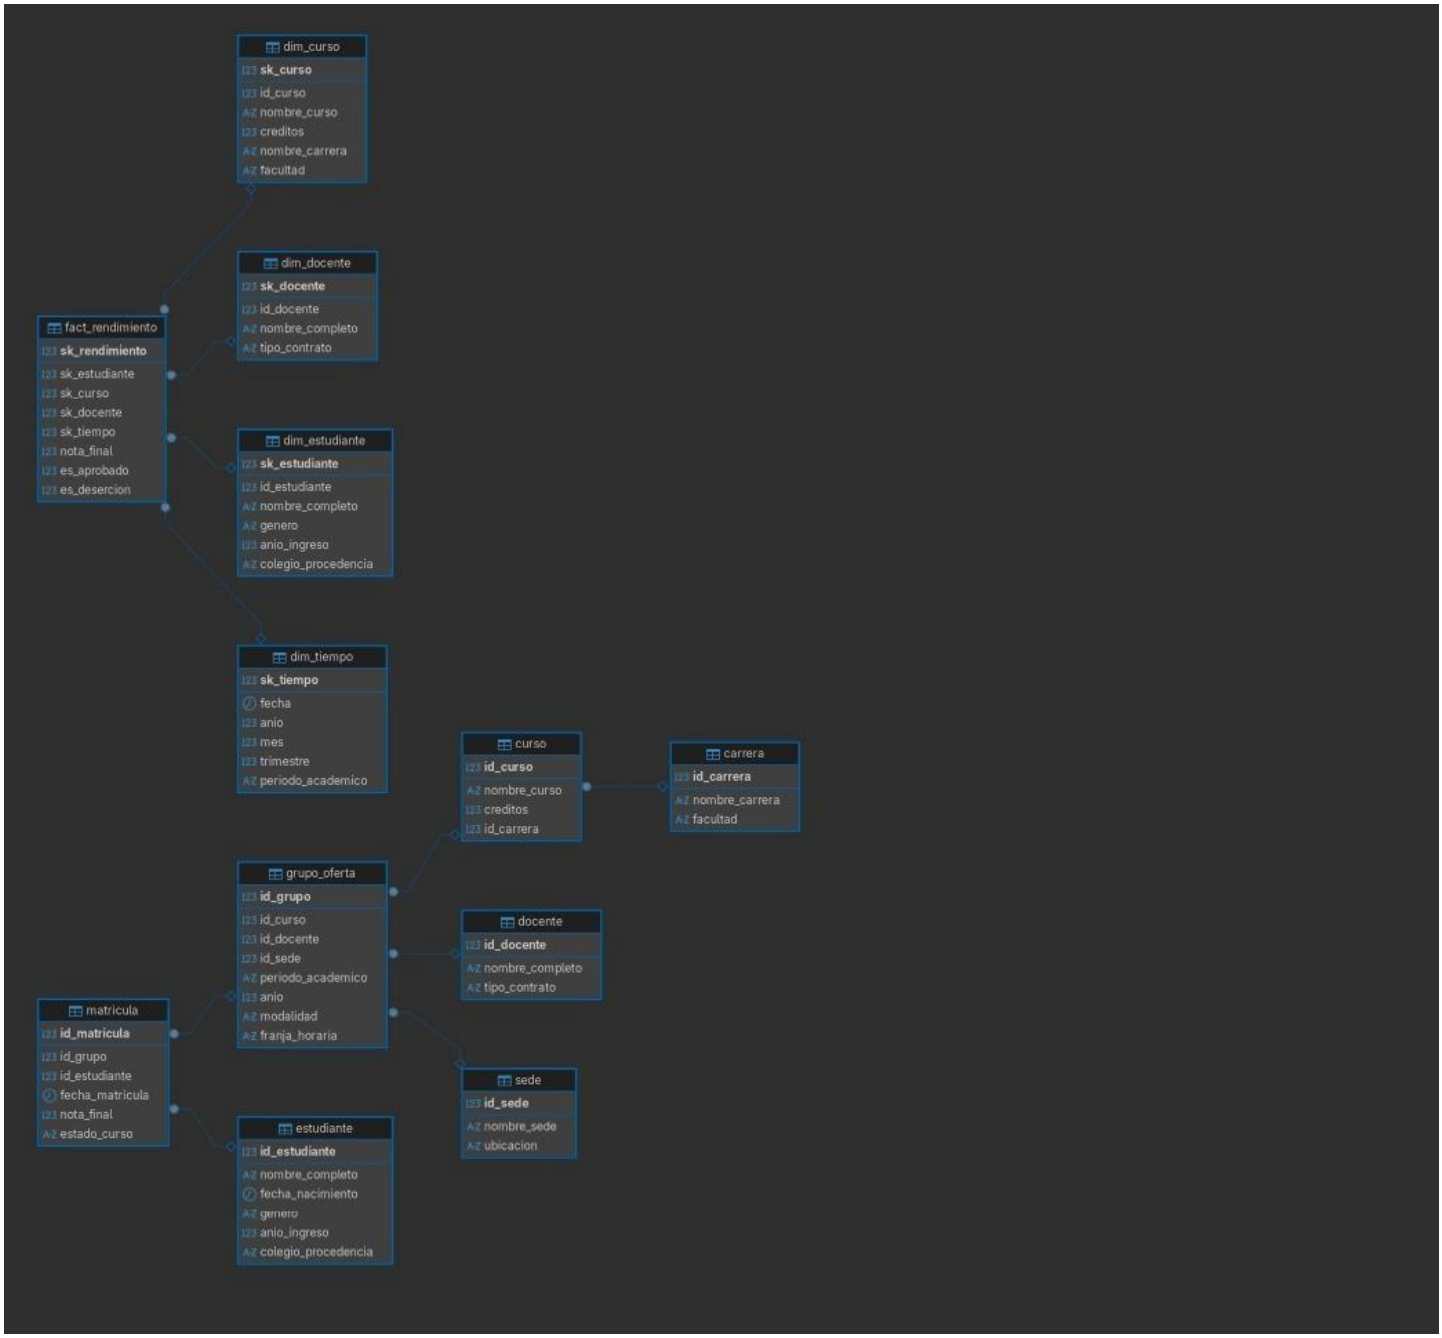
dim_curso
sk_curso
id_curso
nombre_curso
creditos
nombre_carrera
facultad
dim_docente
sk_docente
id_docente
nombre_completo
tipo_contrato
fact_rendimiento
sk_rendimiento
sk_estudiante
sk_curso
sk_docente
sk_tiempo
nota_final
es_aprobado
es_desercion
dim_estudiante
sk_estudiante
id_estudiante
nombre_completo
genero
anio_ingreso
colegio_procedencia
dim_tiempo
sk_tiempo
fecha
anio
mes
trimestre
periodo_academico
curso
id_curso
nombre_curso
creditos
id_carrera
carrera
id_carrera
nombre_carrera
facultad
grupo_oferta
id_grupo
id_curso
id_docente
id_sede
periodo_academico
anio
modalidad
franja_horaria
docente
id_docente
nombre_completo
tipo_contrato
matricula
id_matricula
id_grupo
id_estudiante
fecha_matricula
nota_final
estado_curso
sede
id_sede
nombre_sede
ubicacion
estudiante
id_estudiante
nombre_completo
fecha_nacimiento
genero
anio_ingreso
colegio_procedencia

Diseño Modelo Dimensional

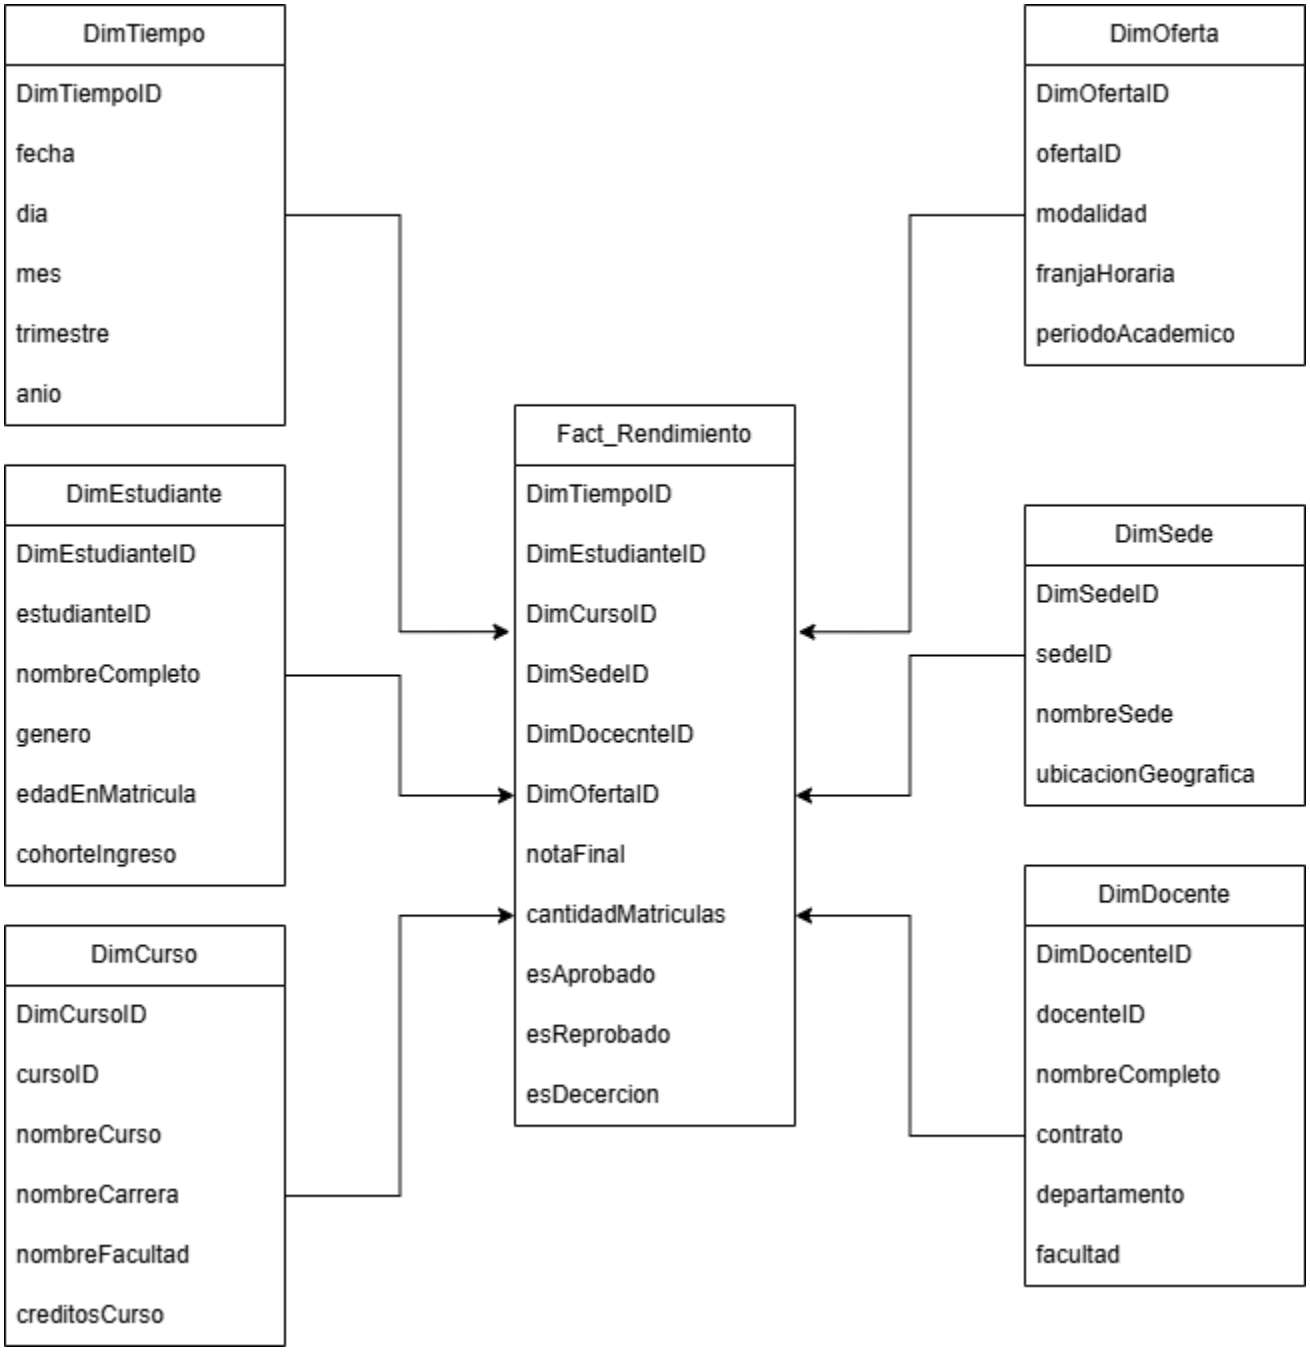

<u>Granularidad:</u> Un registro por cada estudiante matriculado en un curso específico, impartido por un docente en una sede y franja horaria determinada, para un periodo académico dado.

<u>Definición de Dimensiones y Jerarquías:</u>

1. **Dimensión Tiempo (DimTiempo)**
   Jerarquía: Anio > Trimestre > Mes > Fecha.
   Atributos: Incluye campos para filtrado como el nombre del mes y el número de trimestre.
2. **Dimensión Estudiante (DimEstudiante)**
   Atributos Clave: genero, edadEnMatricula y cohorteIngreso (fundamental para el análisis de permanencia académica).
3. **Dimensión Curso (DimCurso).**
   Jerarquía: Facultad > Carrera > Curso.

Atributos Clave: nombreFacultad, nombreCarrera y creditosCurso.

4. **Dimensión Docente (DimDocente)**
   Jerarquía: Facultad > Departamento > Docente.
   Atributos Clave: nombreCompleto, contrato (tipo de contratación) y departamento.
5. **Dimensión Oferta (DimOferta)**
   Atributos: modalidad (Presencial, Virtual, Híbrido), franjaHoraria (Mañana, Tarde, Noche) y periodoAcademico.
6. **Dimensión Sede (DimSede)**
   Atributos: nombreSede y ubicacionGeografica.

Tabla de Hechos (Fact_Rendimiento)

Llaves Subrogadas: DimTiempoID, DimEstudianteID, DimCursoID, DimSedeID, DimDocenteID, DimOfertaID.

Medidas:

notaFinal: Valor numérico del desempeño.

cantidadMatriculas: Hecho aditivo (siempre 1) para conteo de inscripciones.

Indicadores de Estado: esAprobado, esReprobado, esDesercion.

Diccionario de Datos

Entidad (Tabla)	Columna	Tipo de Dato	Descripción
Fact_Rendimiento	DimTiempoID	INT	Llave foránea (FK) hacia la dimensión tiempo.
Fact_Rendimiento	DimEstudianteID	INT	Llave foránea (FK) hacia la dimensión estudiante.
Fact_Rendimiento	DimCursoID	INT	Llave foránea (FK) hacia la dimensión curso.
Fact_Rendimiento	DimSedeID	INT	Llave foránea (FK) hacia la dimensión sede.
Fact_Rendimiento	DimDocenteID	INT	Llave foránea (FK) hacia la dimensión docente.

Entidad (Tabla)	Columna	Tipo de Dato	Descripción
Fact_Rendimiento	DimOfertaID	INT	Llave foránea (FK) hacia la dimensión oferta.
Fact_Rendimiento	notaFinal	DECIMAL	Métrica de la calificación obtenida por el estudiante.
Fact_Rendimiento	cantidadMatriculas	INT	Contador de registros (valor 1).
Fact_Rendimiento	esAprobado	BIT/INT	Indicador: 1 si aprobó el curso, 0 de lo contrario.
Fact_Rendimiento	esReprobado	BIT/INT	Indicador: 1 si reprobó el curso, 0 de lo contrario.
Fact_Rendimiento	esDesercion	BIT/INT	Indicador: 1 si el estudiante abandonó el curso.
DimTiempo	DimTiempoID	INT (PK)	Llave subrogada (SK) única para el tiempo.
DimTiempo	fecha	DATE	Fecha calendario completa (DD/MM/AA).
DimTiempo	dia	INT	Número de día del mes.
DimTiempo	mes	INT	Número de mes (1-12).
DimTiempo	trimestre	INT	Número de trimestre (1-4).

Entidad (Tabla)	Columna	Tipo de Dato	Descripción
DimTiempo	anio	INT	Año de la transacción académica.
DimEstudiante	DimEstudianteID	INT (PK)	Llave subrogada (SK) para el estudiante.
DimEstudiante	estudianteID	INT	Llave natural (NK): carné o ID del sistema origen.
DimEstudiante	nombreCompleto	VARCHAR	Nombre completo del estudiante.
DimEstudiante	genero	VARCHAR	Género del estudiante para análisis demográfico.
DimEstudiante	edadEnMatricula	INT	Edad del estudiante al momento de matricular.
DimEstudiante	cohorteIngreso	INT	Año de ingreso a la carrera (Análisis de permanencia).
DimCurso	DimCursoID	INT (PK)	Llave subrogada (SK) para el curso.
DimCurso	cursoID	INT	Llave natural (NK): código operacional del curso.
DimCurso	nombreCurso	VARCHAR	Nombre oficial de la materia.
DimCurso	nombreCarrera	VARCHAR	Carrera a la que pertenece el curso .
DimCurso	nombreFacultad	VARCHAR	Facultad responsable.
DimCurso	creditosCurso	INT	Créditos académicos que otorga el curso.

Entidad (Tabla)	Columna	Tipo de Dato	Descripción
DimDocente	DimDocenteID	INT (PK)	Llave subrogada (SK) para el docente.
DimDocente	docenteID	INT	Llave natural (NK): ID del profesor en origen.
DimDocente	nombreCompleto	VARCHAR	Nombre completo del docente.
DimDocente	contrato	VARCHAR	Tipo de contrato (Tiempo completo, Por horas, etc.).
DimDocente	departamento	VARCHAR	Departamento académico.
DimDocente	facultad	VARCHAR	Facultad a la que pertenece el docente.
DimOferta	DimOfertaID	INT (PK)	Llave subrogada (SK) para la oferta académica.
DimOferta	ofertaID	INT	Llave natural (NK): identificador del grupo.
DimOferta	modalidad	VARCHAR	Virtual, Presencial o Híbrido.
DimOferta	franjaHoraria	VARCHAR	Mañana, Tarde o Noche.
DimOferta	periodoAcademico	VARCHAR	Semestre o ciclo lectivo analizado.
DimSede	DimSedeID	INT (PK)	Llave subrogada (SK) para la sede.
DimSede	sedeID	INT	Llave natural (NK): código físico de la sede.
DimSede	nombreSede	VARCHAR	Nombre del campus o centro académico.
DimSede	ubicacionGeografica	VARCHAR	Ubicación física de la sede.

Diseño ETL

El proceso ETL implementado transfiere datos desde una base de datos transaccional (OLTP) hacia un Data Warehouse dimensional (Star Schema). Se diseñó en tres etapas diferenciadas:

Etapa	Descripción	Herramienta utilizada
Extracción	Los datos fuente fueron cargados manualmente al esquema staging mediante el archivo Datos_Ins_Universitaria.sql ejecutado directamente en PostgreSQL.	psql / PostgreSQL
Transformación y Carga — Dimensiones	Las cinco dimensiones se poblaron con sentencias INSERT...SELECT directas desde el staging, aplicando las reglas de limpieza y transformación en SQL.	psql / PostgreSQL
Transformación y Carga — Tabla de Hechos	Apache NiFi 2.8.0 orquesta la carga de fact_rendimiento mediante un flow con ExecuteSQL y PutDatabaseRecord. El SQL del ExecuteSQL realiza los JOINs con las dimensiones para resolver las surrogate keys y deriva los flags de negocio.	Apache NiFi 2.8.0

El flujo en Apache NiFi para la tabla de hechos es:

ExecuteSQL → PutDatabaseRecord

Esta arquitectura simplificada fue el resultado de un proceso iterativo de resolución de problemas. Se evaluó el uso de LookupRecord para resolver surrogate keys en NiFi, pero se determinó que delegarle los JOINs directamente a PostgreSQL mediante el ExecuteSQL era más confiable, eficiente y libre de problemas de conversión de tipos entre formatos Avro y JSON.

Reglas de Limpieza

Las siguientes reglas de limpieza fueron identificadas y aplicadas durante el proceso ETL:

#	Problema detectado	Campo afectado	Acción tomada
1	Fecha de nacimiento inválida: el estudiante con id_estudiante=2023001 tiene fecha_nacimiento='0000-00-00' en la fuente.	Estudiante.fecha_nacimiento	Se omite el campo en dim_estudiante ya que la dimensión no incluye fecha_nacimiento directamente. El campo anio_ingreso (cohorte) sí es válido y se preserva.
2	Valores TEXT con padding de espacios: al cargar el staging con INSERT desde SQL, los campos id_sede, id_curso, id_docente, id_estudiante e id_grupo quedaron con espacios al final por ser columnas TEXT de longitud fija.	Todos los campos id_* en staging	Se aplica TRIM() en los JOINs del SQL del ExecuteSQL: TRIM(m.id_estudiante) = TRIM(e.id_estudiante). También se ejecutó UPDATE ... SET id_x = TRIM(id_x) en las tablas del DW antes de los lookups.
3	Tipos incompatibles entre staging (TEXT) y DW (INT/FLOAT): nota_final y anio llegaban como TEXT desde el staging.	stg_matricula.nota_final, stg_grupo_oferta.anio	Se aplica CAST(m.nota_final AS FLOAT) en el SQL del ExecuteSQL. Para dim_grupo_oferta se usa CAST(anio AS INT) en el INSERT directo desde psql.

#	Problema detectado	Campo afectado	Acción tomada
4	Estado de deserción con tilde: el valor 'Deserción' contiene carácter especial que puede causar fallos en comparaciones de texto.	stg_matricula.estado_curso	Se usa comparación directa con el valor exacto: estado_curso = 'Deserción' en el CASE del SQL. Se verificó que el encoding de PostgreSQL soporta UTF-8.

Reglas de Transformación

Las siguientes transformaciones se aplican en el SQL del procesador ExecuteSQL de Apache NiFi durante la carga de fact_rendimiento:

#	Campo destino	Transformación	Expresión SQL
1	fact_rendimiento.sk_estudiante	Resolución de surrogate key mediante JOIN con dim_estudiante usando la natural key id_estudiante con TRIM para eliminar espacios.	JOIN dim_estudiante e ON TRIM(m.id_estudiante) = TRIM(e.id_estudiante)
2	fact_rendimiento.sk_curso	Resolución de surrogate key mediante JOIN con dim_curso usando id_curso del grupo de oferta con TRIM.	JOIN dim_curso c ON TRIM(go.id_curso) = TRIM(c.id_curso)
3	fact_rendimiento.sk_docente	Resolución de surrogate key mediante JOIN con dim_docente usando id_docente del grupo de oferta con TRIM.	JOIN dim_docente d ON TRIM(go.id_docente) = TRIM(d.id_docente)
4	fact_rendimiento.sk_sede	Resolución de surrogate key mediante JOIN con dim_sede usando id_sede del grupo de oferta con TRIM.	JOIN dim_sede s ON TRIM(go.id_sede) = TRIM(s.id_sede)
5	fact_rendimiento.sk_grupo	Resolución de surrogate key mediante JOIN con dim_grupo_oferta usando id_grupo de la matrícula con TRIM.	JOIN dim_grupo_oferta g ON TRIM(m.id_grupo) = TRIM(g.id_grupo)
6	fact_rendimiento.nota_final	Conversión de tipo TEXT a FLOAT para garantizar precisión numérica en el DW.	CAST(m.nota_final AS FLOAT)
7	fact_rendimiento.es_aprobado	Derivación de flag binario: 1 si nota >= 70, 0 en caso contrario.	CASE WHEN CAST(m.nota_final AS FLOAT) >= 70 THEN 1 ELSE 0 END
8	fact_rendimiento.es_reprobado	Derivación de flag binario: 1 si nota < 70 Y el estado no es Deserción.	CASE WHEN CAST(m.nota_final AS FLOAT) < 70 AND

#	Campo destino	Transformación	Expresión SQL
			m.estado_curso != 'Deserción' THEN 1 ELSE 0 END
9	fact_rendimiento.es_desercion	Derivación de flag binario: 1 si el estado del curso es Deserción.	CASE WHEN m.estado_curso = 'Deserción' THEN 1 ELSE 0 END

Reglas de Carga

El proceso de carga se divide en dos subprocesos según el destino:

Carga de Dimensiones (SQL directo desde psql)

Las dimensiones se cargan ejecutando sentencias INSERT...SELECT directas en PostgreSQL. El orden de carga es el siguiente para respetar la integridad referencial:

Orden	Tabla destino	Tabla(s) origen en staging	Observaciones
1	dim_estudiante	stg_estudiante	Carga directa. Sin transformaciones complejas excepto preservar anio_ingreso como cohorte.
2	dim_curso	stg_curso + stg_carrera	JOIN entre stg_curso y stg_carrera para desnormalizar nombre_carrera y facultad en la dimensión.
3	dim_docente	stg_docente	Carga directa sin transformaciones.
4	dim_sede	stg_sede	Carga directa sin transformaciones.
5	dim_grupo_oferta	stg_grupo_oferta	Requiere CAST(anio AS INT) por incompatibilidad de tipos entre staging (TEXT) y DW (INT).

Carga de Tabla de Hechos (Apache NiFi)

La tabla fact_rendimiento se carga mediante el flow de NiFi. Las reglas de carga son:

Regla	Descripción
Modo de inserción	INSERT — no se permiten duplicados. Antes de cada ejecución del flow se ejecuta TRUNCATE TABLE fact_rendimiento para garantizar una carga limpia.
Ejecución del flow	El procesador ExecuteSQL se ejecuta con Run Once para evitar que el flow se ejecute en loop continuo y genere duplicados en la fact table.
Granularidad	Una fila por matrícula (combinación única de estudiante × grupo × periodo). Corresponde directamente a un registro de stg_matricula.
Manejo de no coincidencias	Los registros que no encuentren match en alguna dimensión son descartados. En este dataset no se presentaron casos de no coincidencia una vez aplicado el TRIM en los JOINs.

Regla	Descripción
Formato del FlowFile	El ExecuteSQL emite Avro. El PutDatabaseRecord usa AvroReader para leer directamente sin conversiones intermedias de formato.

Cuadro de Mapeo de Datos (Origen y Destino)

Para cada tabla del DW se documenta el origen de cada campo, la regla aplicada y comentarios relevantes.

dim_estudiante:

Origen: staging.stg_estudiante

Campo Destino	Campo Origen	Regla Aplicada	Comentarios
dim_estudiante.sk_estudiante	—	SERIAL AUTO_INCREMENT generado por PostgreSQL	Surrogate key — no existe en la fuente
dim_estudiante.id_estudiante	stg_estudiante.id_estudiante	TRIM() — eliminar espacios residuales	Natural key — conservada para trazabilidad y lookups del ETL
dim_estudiante.nombre_completo	stg_estudiante.nombre_completo	Copia directa	
dim_estudiante.genero	stg_estudiante.genero	Copia directa	
dim_estudiante.anio_ingreso	stg_estudiante.anio_ingreso	Copia directa — representa la cohorte	anio_ingreso = cohorte académica del estudiante
dim_estudiante.colegio_procedencia	stg_estudiante.colegio_procedencia	Copia directa	

dim_curso:

Origen: staging.stg_curso JOIN staging.stg_carrera ON id_carrera — dimensión desnormalizada

Campo Destino	Campo Origen	Regla Aplicada	Comentarios
dim_curso.sk_curso	—	SERIAL AUTO_INCREMENT	Surrogate key
dim_curso.id_curso	stg_curso.id_curso	TRIM()	Natural key

Campo Destino	Campo Origen	Regla Aplicada	Comentarios
dim_curso.nombre_curso	stg_curso.nombre_curso	Copia directa	
dim_curso.creditos	stg_curso.creditos	Copia directa	
dim_curso.nombre_carrera	stg_carrera.nombre_carrera	Copia directa vía JOIN — desnormalización	Se evita snowflake innecesario
dim_curso.facultad	stg_carrera.facultad	Copia directa vía JOIN — desnormalización	

dim_docente:

Origen: staging.stg_docente

Campo Destino	Campo Origen	Regla Aplicada	Comentarios
dim_docente.sk_docente	—	SERIAL AUTO_INCREMENT	Surrogate key
dim_docente.id_docente	stg_docente.id_docente	TRIM()	Natural key
dim_docente.nombre_completo	stg_docente.nombre_completo	Copia directa	
dim_docente.tipo_contrato	stg_docente.tipo_contrato	Copia directa	Ej: Tiempo Completo, Por Horas

dim_sede:

Origen: staging.stg_sede

Campo Destino	Campo Origen	Regla Aplicada	Comentarios
dim_sede.sk_sede	—	SERIAL AUTO_INCREMENT	Surrogate key
dim_sede.id_sede	stg_sede.id_sede	TRIM()	Natural key
dim_sede.nombre_sede	stg_sede.nombre_sede	Copia directa	
dim_sede.ubicacion	stg_sede.ubicacion	Copia directa	

dim_grupo_oferta:

Origen: staging.stg_grupo_oferta

Campo Destino	Campo Origen	Regla Aplicada	Comentarios
dim_grupo_oferta.sk_grupo	—	SERIAL AUTO_INCREMENT	Surrogate key
dim_grupo_oferta.id_grupo	stg_grupo_oferta.id_grupo	TRIM()	Natural key
dim_grupo_oferta.periodo_academico	stg_grupo_oferta.periodo_academico	Copia directa	Ej: I Semestre
dim_grupo_oferta.anio	stg_grupo_oferta.anio	CAST(anio AS INT) — conversión de TEXT a INT	Staging almacena como TEXT
dim_grupo_oferta.modalidad	stg_grupo_oferta.modalidad	Copia directa	Presencial / Virtual / Híbrido
dim_grupo_oferta.franja_horaria	stg_grupo_oferta.franja_horaria	Copia directa	Mañana / Tarde / Noche

fact_rendimiento:

Origen: staging.stg_matricula JOIN staging.stg_grupo_oferta JOIN todas las dimensiones. Procesado por Apache NiFi — ExecuteSQL.

Campo Destino	Campo Origen	Regla Aplicada	Comentarios
fact_rendimiento.sk_rendimiento	—	SERIAL AUTO_INCREMENT	Surrogate key de la fact table
fact_rendimiento.sk_estudiante	stg_matricula.id_estudiante	JOIN dim_estudiante ON TRIM(id_estudiante) — retorna sk_estudiante	Resolución de SK en SQL
fact_rendimiento.sk_curso	stg_grupo_oferta.id_curso	JOIN dim_curso ON TRIM(id_curso) — retorna sk_curso	Via JOIN con stg_grupo_oferta
fact_rendimiento.sk_docente	stg_grupo_oferta.id_docente	JOIN dim_docente ON TRIM(id_docente) — retorna sk_docente	Via JOIN con stg_grupo_oferta

Campo Destino	Campo Origen	Regla Aplicada	Comentarios
fact_rendimiento.sk_sede	stg_grupo_oferta.id_sede	JOIN dim_sede ON TRIM(id_sede) — retorna sk_sede	Via JOIN con stg_grupo_oferta
fact_rendimiento.sk_grupo	stg_matricula.id_grupo	JOIN dim_grupo_oferta ON TRIM(id_grupo) — retorna sk_grupo	
fact_rendimiento.nota_final	stg_matricula.nota_final	CAST(nota_final AS FLOAT) — conversión de TEXT a FLOAT	
fact_rendimiento.es_aprobado	stg_matricula.nota_final	CASE WHEN nota >= 70 THEN 1 ELSE 0 END	Flag binario derivado
fact_rendimiento.es_reprobado	stg_matricula.nota_final + estado_curso	CASE WHEN nota < 70 AND estado != 'Deserción' THEN 1 ELSE 0 END	Flag binario derivado
fact_rendimiento.es_desercion	stg_matricula.estado_curso	CASE WHEN estado = 'Deserción' THEN 1 ELSE 0 END	Flag binario derivado

Capturas ETL

Las siguientes capturas son requeridas como evidencia de la ejecución del ETL. Se indica qué tomar, desde dónde y qué debe mostrar cada una.

Capturas del Staging (Origen)

#	Qué capturar	Qué debe mostrar
1	Estructura del schema staging	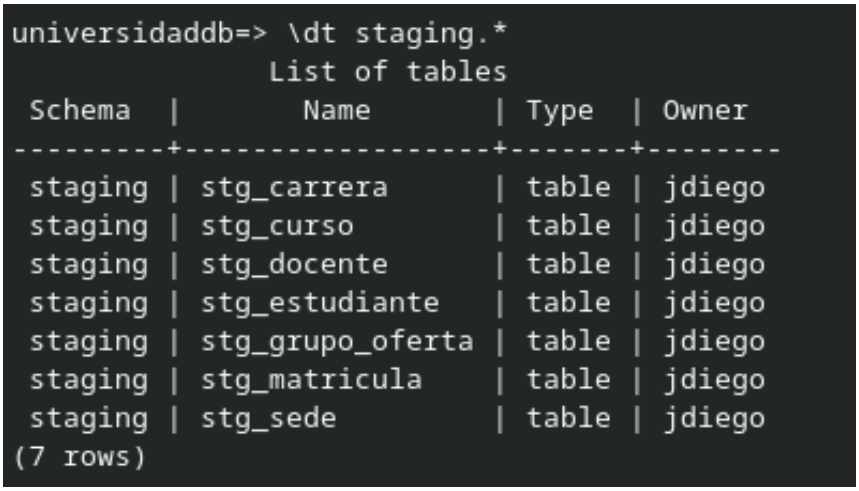

```
universidaddb=> \dt staging.*
                List of tables
 Schema  |        Name        | Type  | Owner
---------+--------------------+-------+--------
 staging | stg_carrera        | table | jdiego
 staging | stg_curso          | table | jdiego
 staging | stg_docente        | table | jdiego
 staging | stg_estudiante     | table | jdiego
 staging | stg_grupo_oferta   | table | jdiego
 staging | stg_matricula      | table | jdiego
 staging | stg_sede           | table | jdiego
(7 rows)
```

#	Qué capturar	Qué debe mostrar

2	Conteo de registros en staging	`universidaddb=> SELECT 'stg_matricula'  AS tabla, COUNT(*) FROM staging.stg_matricula`
		`UNION ALL`
		`SELECT 'stg_estudiante',  COUNT(*) FROM staging.stg_estudiante`
		`UNION ALL`
		`SELECT 'stg_curso',  COUNT(*) FROM staging.stg_curso`
		`UNION ALL`
		`SELECT 'stg_docente',  COUNT(*) FROM staging.stg_docente`
		`UNION ALL`
		`SELECT 'stg_sede',  COUNT(*) FROM staging.stg_sede`
		`UNION ALL`
		`SELECT 'stg_carrera',  COUNT(*) FROM staging.stg_carrera`
		`UNION ALL`
		`SELECT 'stg_grupo_oferta',  COUNT(*) FROM staging.stg_grupo_oferta;`
		`tabla | count`
		`----------+-------`
		` stg_matricula | 200`
		` stg_estudiante | 100`
		` stg_curso | 4`
		` stg_docente | 3`
		` stg_sede | 3`
		` stg_carrera | 3`
		` stg_grupo_oferta | 3`
		`(7 rows)`

3	Muestra de datos fuente	`universidaddb=> SELECT * FROM staging.stg_matricula LIMIT 5;`
		` id_matricula | id_grupo | id_estudiante | fecha_matricula | nota_final | estado_curso`
		`----------+----------+----------+----------+----------+----------`
		` 1 | 1001 | 2023001 | 2026-01-10 | 67.40 | Aprobado`
		` 2 | 1001 | 2023002 | 2026-01-11 | 45.00 | Reprobado`
		` 3 | 1001 | 2024001 | 2026-01-11 | 90.00 | Aprobado`
		` 4 | 1001 | 2024002 | 2026-01-12 | 0.00 | Deserción`
		` 5 | 1001 | 2025001 | 2026-01-12 | 88.00 | Aprobado`
		`(5 rows)`

4	Muestra de estudiantes en staging	` id_estudiante | nombre_completo | fecha_nacimiento | genero | anio_ingreso | colegio_procedencia`
		`----------+----------+----------+----------+----------+----------`
		` 2023001 | Santiago Artavia | 0000-00-00 | Masculino | 2023 | Liceo de Heredia`
		`(1 row)`

Capturas del Flow en Apache NiFi

#	Qué capturar	Qué debe mostrar
5	Vista general del canvas de NiFi	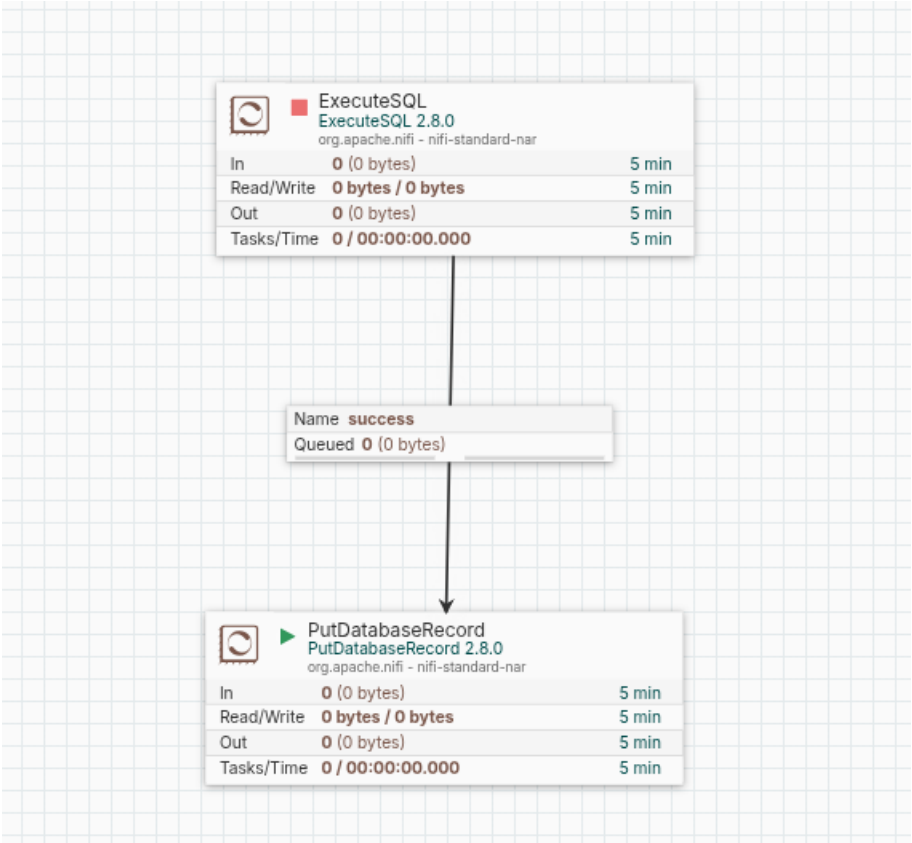
6	Configuración del ExecuteSQL	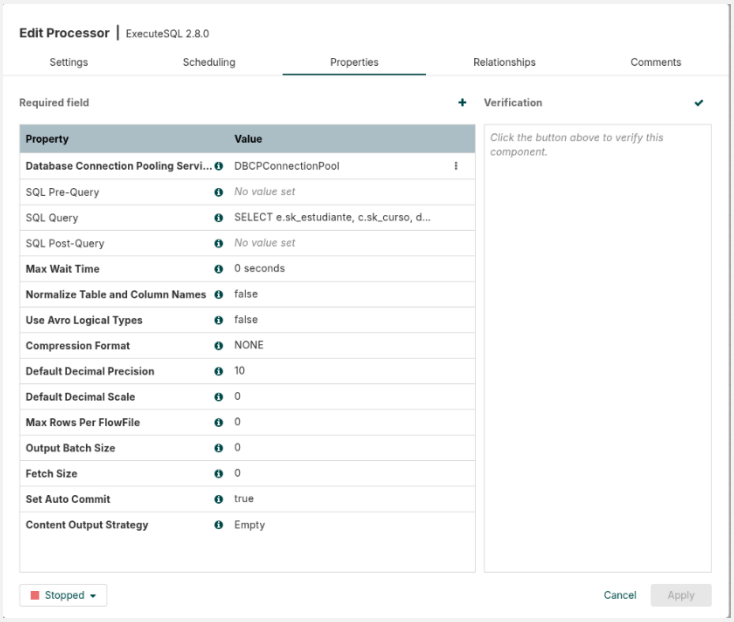

#	Qué capturar	Qué debe mostrar
		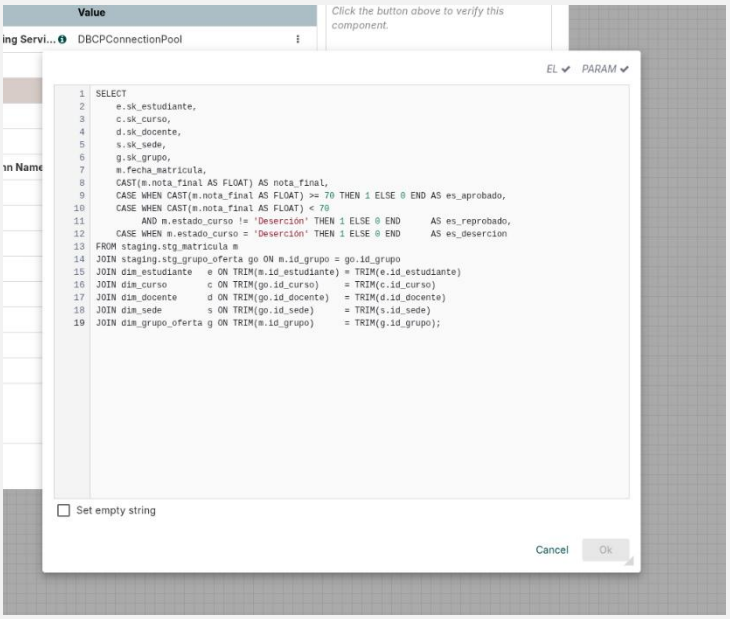
7	Configuración del PutDatabaseRecord	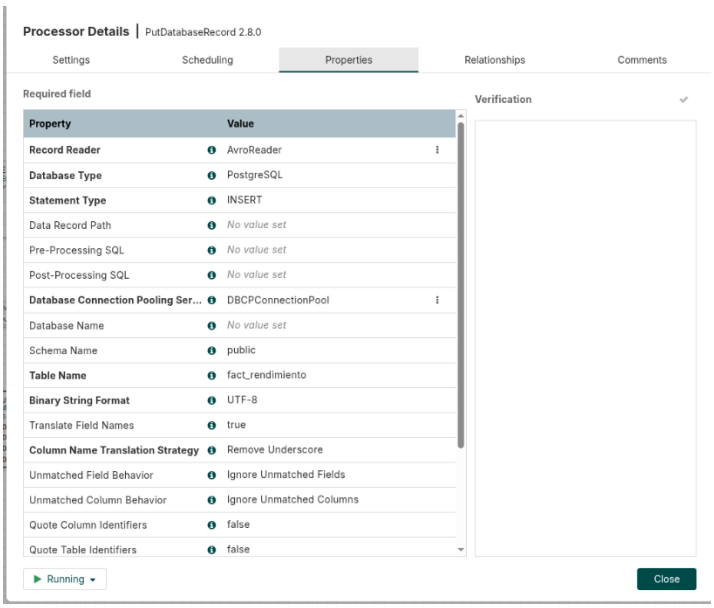

#	Qué capturar	Qué debe mostrar
8	Configuración de la conexión PostgreSQL	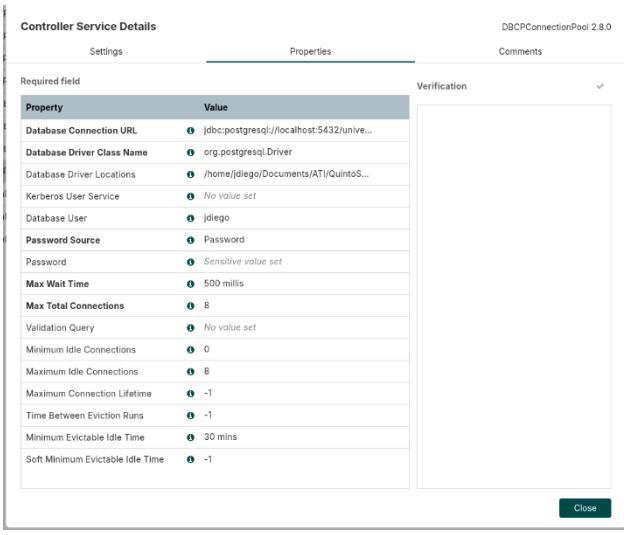

Capturas del DW Destino (PostgreSQL)

#	Qué capturar	Qué debe mostrar
10	Estructura del DW	

```
universidaddb=> \dt public.*
                List of tables
 Schema |        Name        | Type  | Owner
--------+--------------------+-------+--------
 public | carrera            | table | jdiego
 public | curso              | table | jdiego
 public | dim_curso          | table | jdiego
 public | dim_docente        | table | jdiego
 public | dim_estudiante     | table | jdiego
 public | dim_grupo_oferta   | table | jdiego
 public | dim_sede           | table | jdiego
 public | dim_tiempo         | table | jdiego
 public | docente            | table | jdiego
 public | estudiante         | table | jdiego
 public | fact_rendimiento   | table | jdiego
 public | grupo_oferta       | table | jdiego
 public | matricula          | table | jdiego
 public | sede               | table | jdiego
(14 rows)
```

#	Qué capturar	Qué debe mostrar

11	Conteo y validación de SKs sin NULLS	`universidaddb=> SELECT 'dim_estudiante'  AS tabla, COUNT(*) FROM dim_estudiante`
		`UNION ALL`
		`SELECT 'dim_curso',  COUNT(*) FROM dim_curso`
		`UNION ALL`
		`SELECT 'dim_docente',  COUNT(*) FROM dim_docente`
		`UNION ALL`
		`SELECT 'dim_sede',  COUNT(*) FROM dim_sede`
		`UNION ALL`
		`SELECT 'dim_grupo_oferta',  COUNT(*) FROM dim_grupo_oferta`
		`UNION ALL`
		`SELECT 'fact_rendimiento',  COUNT(*) FROM fact_rendimiento;`
		`tabla | count`
		`---+---`
		`dim_estudiante | 100`
		`dim_curso | 4`
		`dim_docente | 3`
		`dim_sede | 3`
		`dim_grupo_oferta | 3`
		`fact_rendimiento | 200`
		`(6 rows)`

12	Distribución de flags	`universidaddb=> SELECT`
		`es_aprobado,`
		`es_reprobado,`
		`es_desercion,`
		`COUNT(*) AS total`
		`FROM fact_rendimiento`
		`GROUP BY es_aprobado, es_reprobado, es_desercion`
		`ORDER BY es_aprobado, es_reprobado, es_desercion;`
		`es_aprobado | es_reprobado | es_desercion | total`
		`---+---+---+---`
		`0 | 0 | 1 | 21`
		`0 | 1 | 0 | 61`
		`1 | 0 | 0 | 118`
		`(3 rows)`
		`universidaddb=>`

13	Join completo con dimensiones	`universidaddb=> SELECT`
		`e.nombre_completo AS estudiante,`
		`c.nombre_curso,`
		`c.nombre_carrera,`
		`d.nombre_completo AS docente,`
		`d.tipo_contrato,`
		`s.nombre_sede,`
		`g.modalidad,`
		`g.franja_horaria,`
		`g.periodo_academico,`
		`f.nota_final,`
		`f.es_aprobado,`
		`f.es_reprobado,`
		`f.es_desercion`
		`FROM fact_rendimiento f`
		`JOIN dim_estudiante e ON f.sk_estudiante = e.sk_estudiante`
		`JOIN dim_curso c ON f.sk_curso = c.sk_curso`
		`JOIN dim_docente d ON f.sk_docente = d.sk_docente`
		`JOIN dim_sede s ON f.sk_sede = s.sk_sede`
		`JOIN dim_grupo_oferta g ON f.sk_grupo = g.sk_grupo`
		`LIMIT 10;`
		`estudiante | nombre_curso | nombre_carrera | docente | tipo_contrato | nombre_sede | modalidad | franja_horaria | periodo_academico | nota_final | es_aprobado | es_reprobado | es_desercion`
		`---+---+---+

Decisiones de Diseño ETL y Lecciones Aprendidas

Decisiones tomadas

Decisión	Alternativa considerada	Justificación
Usar JOINs en el SQL del ExecuteSQL para resolver surrogate keys	LookupRecord de NiFi para cada dimensión	Los LookupRecord presentaron problemas persistentes de tipos de datos entre Avro, JSON e INTEGER/VARCHAR en PostgreSQL. El JOIN en SQL es más confiable, eficiente y fácil de debuggear.
Staging con todos los campos como TEXT	Staging con tipos de datos definidos	Al usar TEXT en el staging se evitan errores de carga por tipos incompatibles entre la fuente y el staging. Las conversiones se aplican al momento de cargar el DW.
Dimensión dim_curso desnormalizada (incluye datos de Carrera)	Mantener dim_carrera separada (Snowflake)	El modelo Star Schema prioriza la simplicidad de las queries analíticas. La desnormalización elimina JOINs adicionales en las consultas del dashboard.
Flags binarios es_aprobado, es_reprobado, es_desercion en la fact table	Solo almacenar estado_curso como texto	Los flags permiten usar SUM() y AVG() directamente en las consultas analíticas sin necesidad de CASE en cada query del dashboard.
TRUNCATE antes de cada carga de la fact table	INSERT incremental con control de duplicados	Dado que el dataset es completo y estático, el TRUNCATE garantiza una carga limpia sin lógica adicional de detección de duplicados.

Limitaciones del dataset:

El dataset contiene únicamente grupos de oferta del I Semestre 2026, lo que limita el análisis longitudinal de cohortes y la comparación entre periodos académicos. Para un análisis más completo se requeriría generar datos sintéticos adicionales para periodos anteriores (2023, 2024, 2025), lo cual representa una mejora futura identificada para este proyecto.

Limpieza y Validación de datos sintéticos:

Se realizó una revisión exhaustiva de los datos insertados en las tablas de staging para garantizar su coherencia con un entorno universitario real. A continuación, se documentan los hallazgos y correcciones aplicadas.

Error 1 : Fecha de nacimiento inválida

Problema: El estudiante Santiago Artavia (id_estudiante: 2023001) tenía fecha_nacimiento = '0000-00-00', un valor imposible que viola la integridad de los datos.

Campo	Valor Original	Valor Corregido	Justificación
id_estudiante	2023001	2023001	Sin cambio

nombre_completo	Santiago Artavia	Santiago Artavia	Sin cambio
fecha_nacimiento	0000-00-00	2004-03-15	Consistente con ingreso 2023 (18 años)
anio_ingreso	2023	2023	Sin cambio

Error 2: Inconsistencia entre nota y estado del curso

Problema: El mismo estudiante (id_matricula: 1, Santiago Artavia, Grupo 1001) tenía nota_final = 67.40 con estado_curso = 'Aprobado'. Dado que el umbral de aprobación es 70 puntos, esto es una contradicción lógica.

Campo	Valor Original	Valor Corregido	Justificación
id_matricula	1	1	Sin cambio
nota_final	67.40	67.40	Nota correcta
estado_curso	Aprobado	Reprobado	67.40 < 70 → Reprobó

Error 3: Brecha en el flujo ETL

Problema: La consulta SQL del procesador ExecuteSQL no incluye sk_tiempo en el SELECT, dejando la llave foránea hacia dim_tiempo sin poblar en fact_rendimiento. Esto es una omisión crítica ya que dim_tiempo es una dimensión obligatoria del modelo.

Consulta original	Corrección recomendada
No incluye sk_tiempo ni JOIN con dim_tiempo	JOIN dim_tiempo t ON m.fecha_matricula = t.fecha, SELECT t.sk_tiempo

Observaciones Adicionales de Calidad de Datos:

Observación	Descripción	Impacto
Curso sin oferta	Taller de Diseño I (id_curso: 301) no tiene grupo de oferta registrado.	El curso de Diseño Industrial no genera métricas; limita análisis por carrera.
Periodo único	Todos los datos corresponden al I Semestre 2026 únicamente.	Imposibilita el análisis de tendencias temporales o comparación entre semestres.
Deserción con nota 0	Las matrículas en estado 'Deserción' tienen nota = 0.00 de forma consistente.	Correcto y coherente. El ETL usa CASE ≥ 70 que lo trata correctamente.
Join TEXT vs INT en ETL	TRIM(m.id_estudiante) se compara con e.id_estudiante (INT en dim). Puede fallar.	Mejor agregar CAST explícito para evitar errores de tipo en PostgreSQL.

Validación de la solución analítica

Se verificaron manualmente los resultados esperados del dashboard y los reportes analíticos, calculando métricas clave directamente desde los datos de staging corregidos. Los resultados a continuación sirven como valores de referencia para validar la solución implementada.

Métricas Globales del Período

Métrica	Valor Calculado	Observación
Total de matrículas	200	3 grupos, I Semestre 2026
Tasa de aprobación	59.5% (119 estudiantes)	Por debajo del 70% deseable
Tasa de reprobación	30.0% (60 estudiantes)	Alta, requiere atención académica
Tasa de deserción	10.5% (21 estudiantes)	Concentrada en cohortes recientes
Nota promedio global	74.63 / 100	Excluye deserciones

Rendimiento por Grupo y Curso

Grupo	Curso	Docente	Aprobados	Reprobados	Deserciones	Promedio
1001	Intro. Programación	Dra. María Alfaro	40 (60%)	21 (31%)	6 (9%)	75.1
1002	Bases de Datos I	Ing. Carlos Mendoza	39 (58%)	20 (30%)	8 (12%)	73.6
1003	Contabilidad Básica	MSc. Elena Rodríguez	40 (61%)	19 (29%)	7 (11%)	75.2

Validación: El Grupo 1003 (Contabilidad Básica, modalidad Híbrida, franja Tarde) presenta el mejor desempeño con 61% de aprobación y la nota promedio más alta (75.2). El Grupo 1002 (Virtual, Noche) es el de menor rendimiento.

Rendimiento por cohorte

Cohorte	Matrículas	Aprobación	Reprobación	Deserción	Promedio
2023	38	65.8%	34.2%	0.0%	73.38
2024	60	56.7%	30.0%	13.3%	75.19
2025	67	59.7%	32.8%	7.5%	73.74
2026	35	57.1%	20.0%	22.9%	77.35

Importante: La cohorte 2026 tiene la mayor tasa de deserción (22.9%) pero la nota promedio más alta (77.35) entre quienes permanecen. Esto sugiere una polarización; los que se quedan son los de mayor rendimiento, mientras los más vulnerables desertan rápidamente.

Análisis por Modalidad y Franja Horaria

Modalidad / Franja	Aprobación	Deserción	Nota Promedio	Evaluación
Presencial / Mañana (G-1001)	60%	9%	75.1	Bueno
Virtual / Noche (G-1002)	58%	12%	73.6	Por mejorar
Híbrido / Tarde (G-1003)	61%	11%	75.2	Mejor resultado

Diccionario de Correcciones ETL

Campo destino	Campo origen	Regla aplicada	Comentarios
dim_estudiante.id_estudiante	stg_estudiante.id_estudiante	CAST TEXT → INT	La staging almacena todo como TEXT
dim_estudiante.nombre_completo	stg_estudiante.nombre_completo	TRIM()	Elimina espacios en blanco
dim_estudiante.anio_ingreso	stg_estudiante.anio_ingreso	CAST TEXT → INT	Define la cohorte del estudiante
dim_curso.creditos	stg_curso.creditos	CAST TEXT → INT	La staging almacena créditos como TEXT
dim_tiempo.sk_tiempo	stg_matricula.fecha_matricula	CAST TEXT → DATE, lookup en dim_tiempo	Requiere que dim_tiempo esté precargada con las fechas del período
fact_rendimiento.es_aprobado	stg_matricula.nota_final	CASE WHEN nota >= 70 THEN 1 ELSE 0 END	Umbral de aprobación: 70 puntos
fact_rendimiento.es_desercion	stg_matricula.estado_curso	CASE WHEN estado = 'Deserción' THEN 1 ELSE 0 END	Detección de abandono
stg_estudiante.fecha_nacimiento (corrección)	Valor '0000-00-00'	Reemplazar con '2004-03-15'	Corrección manual: id_estudiante 2023001

stg_matricula.estado_curso (corrección)	Valor 'Aprobado' con nota=67.40	Cambiar a 'Reprobado'	Corrección manual: id_matricula 1, nota < 70

Capturas Dashboard

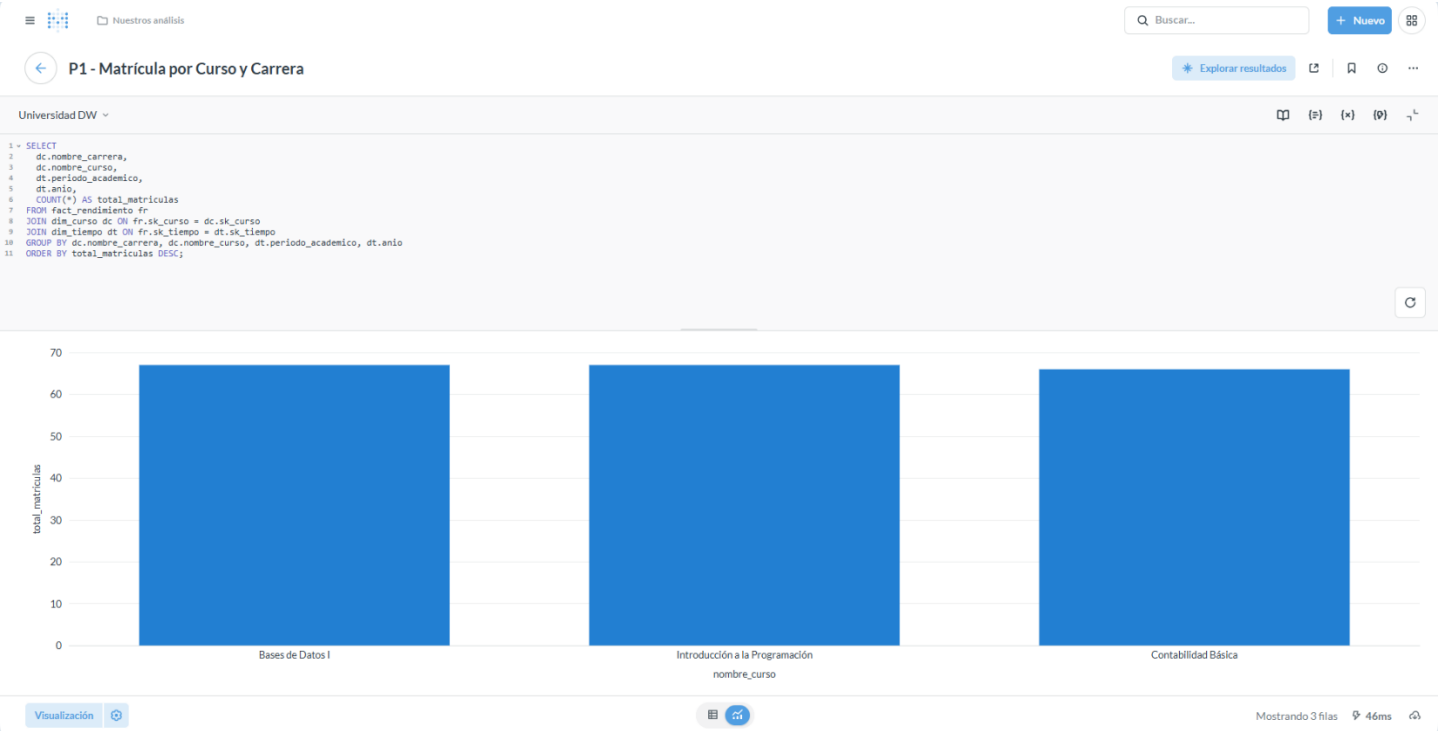

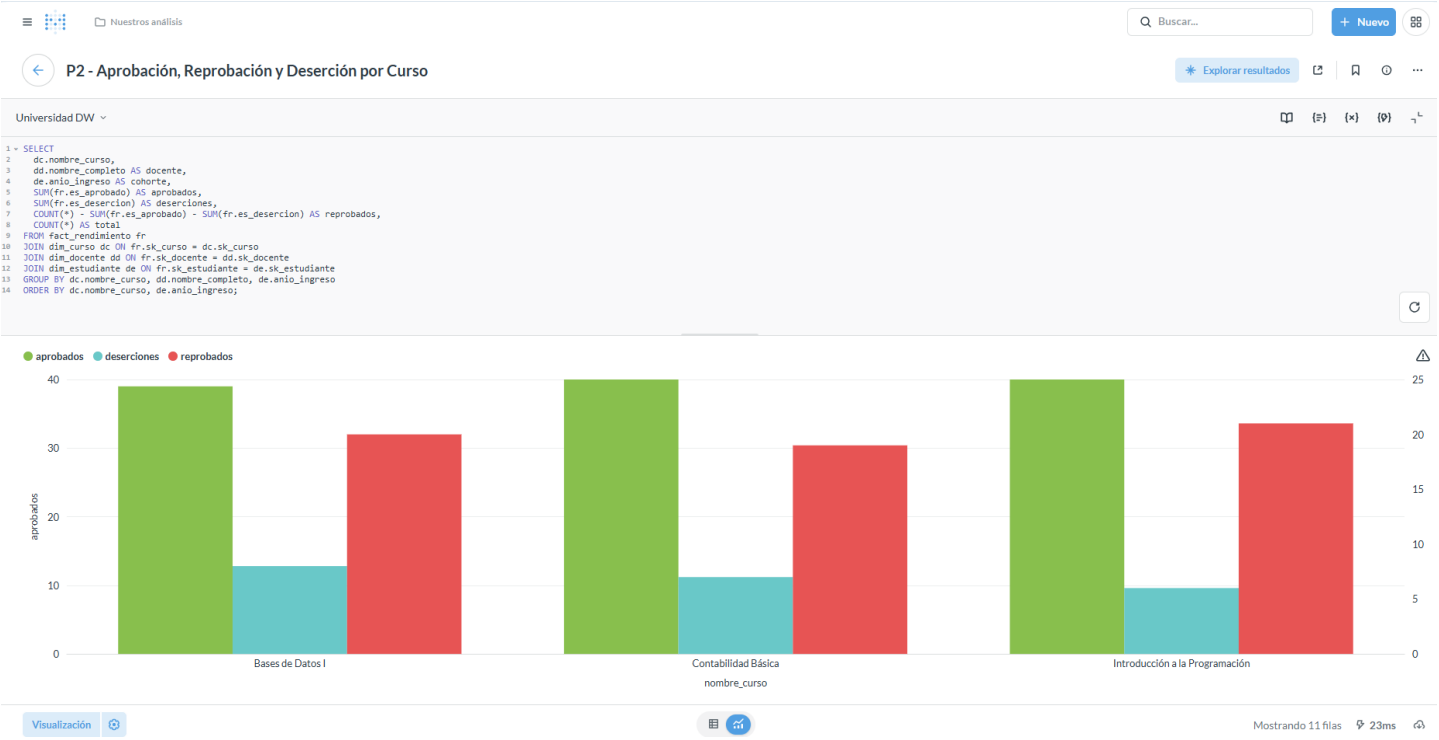

Nuestros análisis

Buscar... + Nuevo

P3 - Perfiles de Riesgo Académico

Explorar resultados

Universidad DW

```
SELECT
  de.genero,
  de.colegio_procedencia,
  de.anio_ingreso AS cohorte,
  COUNT(*) AS total_matriculas,
  SUM(fr.es_desercion) AS deserciones,
  ROUND(AVG(fr.nota_final), 2) AS nota_promedio,
  ROUND(100.0 * SUM(fr.es_desercion) / COUNT(*), 1) AS tasa_desercion
FROM fact_rendimiento fr
JOIN dim_estudiante de ON fr.sk_estudiante = de.sk_estudiante
GROUP BY de.genero, de.colegio_procedencia, de.anio_ingreso
ORDER BY tasa_desercion DESC;
```

genero	colegio_procedencia	cohorte	total_matriculas	deserciones	nota_promedio	tasa_desercion
Femenino	Colegio Bilingüe Vista del Valle	2,026	1	1	0	100
Masculino	Liceo de Orotina	2,026	1	1	0	100
Femenino	Colegio Técnico de Santa Cruz	2,026	1	1	0	100
Femenino	Colegio Angloamericano	2,024	3	2	25.33	66.7
Masculino	Colegio Victoria	2,024	3	2	28.67	66.7
Femenino	Colegio Sagrado Corazón	2,024	2	1	41.5	50
Masculino	Colegio Gregorio José Ramírez	2,025	2	1	46	50
Femenino	Liceo de Flores	2,026	2	1	42.25	50
Femenino	Liceo de Escazú	2,026	2	1	41.25	50
Femenino	Liceo Anastasio Alfaro	2,025	2	1	37.5	50
Masculino	Liceo de Oreamuno	2,024	2	1	46.5	50
Masculino	Liceo de Tilarán	2,026	2	1	40.25	50
Masculino	Liceo de Palmares	2,024	2	1	36.5	50
Masculino	Liceo Samuel Sáenz	2,024	2	1	32.5	50

Visualización

Mostrando 100 filas 34ms

Nuestros análisis

Buscar... + Nuevo

P4 - Aprovechamiento por Modalidad, Franja y Sede

Explorar resultados

Universidad DW

```
SELECT
  go.modalidad,
  go.franja_horaria,
  s.nombre_sede,
  COUNT(*) AS total_matriculas,
  ROUND(AVG(fr.nota_final), 2) AS nota_promedio,
  ROUND(100.0 * SUM(fr.es_aprobado) / COUNT(*), 1) AS tasa_aprobacion
FROM fact_rendimiento fr
JOIN dim_estudiante de ON fr.sk_estudiante = de.sk_estudiante
JOIN dim_tiempo dt ON fr.sk_tiempo = dt.sk_tiempo
JOIN Matricula m ON de.id_estudiante = m.id_estudiante
JOIN Grupo_Oferta go ON m.id_grupo = go.id_grupo
JOIN Sede s ON go.id_sede = s.id_sede
GROUP BY go.modalidad, go.franja_horaria, s.nombre_sede
ORDER BY tasa_aprobacion DESC;
```

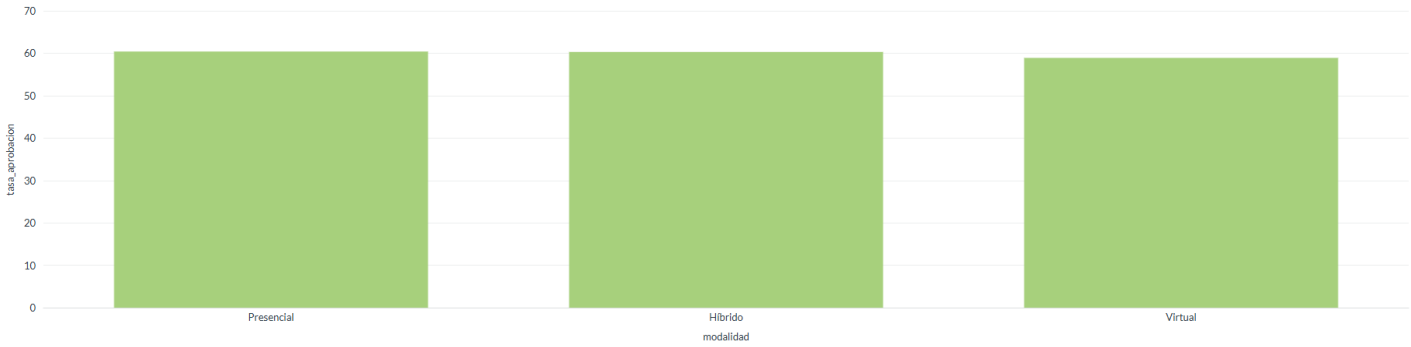

Visualización

Mostrando 3 filas 16ms

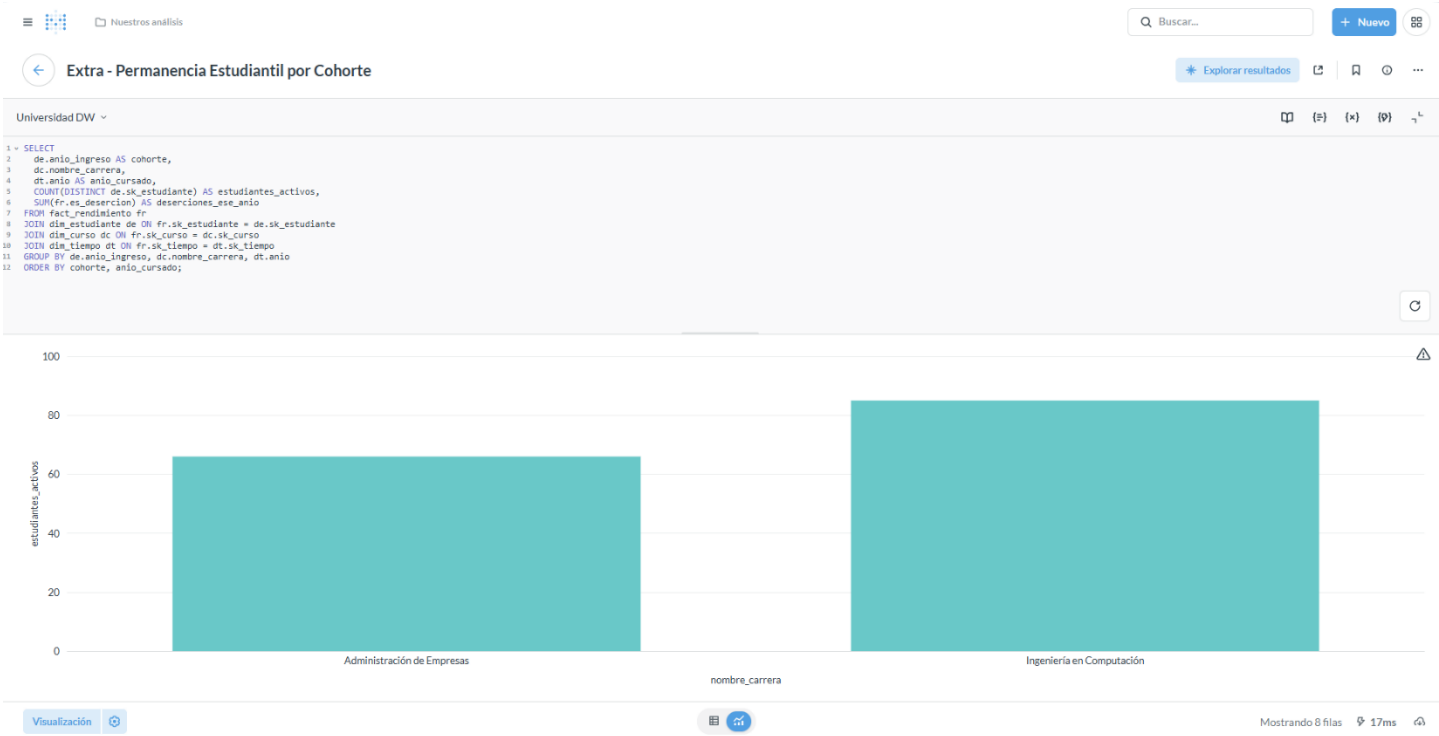

Hallazgos Principales:

Hallazgo 1: La tasa de aprobación global es baja (59.5%)
Solo 6 de cada 10 estudiantes matriculados aprueban el curso. Esto indica un nivel de dificultad elevado o una población estudiantil con necesidades de apoyo académico no atendidas. La nota promedio global de 74.63 está apenas por encima del umbral de aprobación, por lo que evidencia un margen frágil de rendimiento.

Hallazgo 2: La deserción afecta desproporcionadamente a estudiantes de primer ingreso
Los estudiantes de primer ingreso presentan la tasa de deserción más alta, con 22.9%. En contraste, los estudiantes de la cohorte 2023 no registran ninguna deserción. Este patrón es coherente con la literatura sobre permanencia universitaria; los primeros semestres son el período de mayor riesgo de abandono.

Hallazgo 3: La modalidad virtual nocturna concentra el menor rendimiento
El Grupo 1002 (Bases de Datos I, virtual, franja noche) registra la menor tasa de aprobación (58%), la menor nota promedio (73.6) y la mayor deserción (12%). La combinación de modalidad virtual y horario nocturno representa un factor de riesgo académico que debe ser monitoreado con mayor atención.

Hallazgo 4: La modalidad híbrida en horario tarde presenta el mejor resultado
El Grupo 1003 (Contabilidad Básica, híbrido, franja tarde) lidera en aprobación (61%) y nota promedio (75.2). Aunque la muestra es limitada a un solo período, este resultado sugiere que la combinación de presencialidad parcial con flexibilidad horaria puede tener efectos positivos sobre el rendimiento estudiantil.

Hallazgo 5: Polarización de rendimiento en cohortes recientes
Paradójicamente, la cohorte 2026 tiene la nota promedio más alta (77.35) pero la mayor deserción. Esto apunta a un fenómeno de selección; los estudiantes más débiles abandonan tempranamente, elevando artificialmente el promedio del grupo que permanece. Este efecto debe considerarse al interpretar métricas de rendimiento por cohorte.

Respuestas a las preguntas de negocio

Pregunta de Negocio	Respuesta Basada en Datos

¿Qué carreras, cursos o sedes concentran la mayor matrícula?	- Ingeniería en Computación domina con 2 grupos (134 matrículas). - La Sede Central Cartago concentra el 67% de los registros. - Administración de Empresas tiene menor presencia (66 matrículas, 1 grupo). - Diseño Industrial no tiene oferta activa.
¿Cómo se comportan aprobación, reprobación y deserción por curso, docente y cohorte?	Aprobación global: 59.5%. Dra. María Alfaro (G-1001) 60%. Ing. Mendoza (G-1002) 58% MSc. Rodríguez (G-1003) 61% La cohorte 2023 tiene 0% deserción; la 2026 llega al 22.9%.
¿Qué perfiles de estudiante muestran mayor riesgo académico?	Estudiantes de primer ingreso, matriculados en la franja nocturna, en modalidad virtual. Combinación de estas tres variables incrementa el riesgo de deserción y reprobación.
¿Cuáles franjas, modalidades o campus presentan mejor aprovechamiento?	Mejor resultado: franja tarde + modalidad híbrida (G-1003, 61% aprobación). Peor resultado: franja noche + modalidad virtual (G-1002, 58% aprobación, 12% deserción). Campus Cartago concentra mayor matrícula.

Indicador Adicional Propuesto: Índice de Permanencia por Cohorte (IPC)

Como indicador complementario de valor analítico, se propone el Índice de Permanencia por Cohorte (IPC), definido como:

IPC = (Matrículas activas sin deserción / Matrículas totales de la cohorte) × 100

Cohorte	Matrículas	Deserciones	IPC
2023	38	0	100.0%

2024	60	8	86.7%
2025	67	5	92.5%
2026	35	8	77.1%

Este indicador permite visualizar la retención estudiantil por generación de ingreso y alertar sobre cohortes en riesgo de manera temprana.

Limitaciones

- Datos sintéticos de un único período (I Semestre 2026): no es posible realizar análisis de tendencias temporales, estacionalidad ni evolución histórica del rendimiento.
- Muestra reducida: 100 estudiantes en 3 grupos activos limitan la generalización de los hallazgos. Los porcentajes calculados tienen alta varianza con muestras pequeñas.
- Ausencia del curso de Diseño Industrial (301): la carrera de Diseño Industrial no tiene ningún grupo activo, lo que imposibilita el análisis comparativo entre las tres carreras de la institución.
- Brecha en dim_tiempo: el ETL de NiFi no carga sk_tiempo en fact_rendimiento, lo que puede afectar los análisis temporales en herramientas OLAP o dashboards que usen esa dimensión.
- Un solo docente por grupo: sin grupos paralelos del mismo curso impartidos por distintos docentes, no es posible comparar el efecto del docente sobre el rendimiento de forma controlada.

Conclusiones

- La solución de BI implementada cumple con los requisitos mínimos del caso: cuenta con modelo dimensional funcional (dim_estudiante, dim_curso, dim_docente, dim_tiempo, fact_rendimiento), proceso ETL mediante Apache NiFi y componente analítico visual.
- El análisis confirmó que los primeros semestres son críticos para la permanencia estudiantil: la cohorte 2026 presenta una tasa de deserción casi tres veces mayor que la cohorte 2025 y cinco veces mayor que los estudiantes más avanzados.
- La modalidad y franja horaria tienen influencia medible sobre el rendimiento: la modalidad híbrida en horario de tarde supera consistentemente a la modalidad virtual nocturna en aprobación y nota promedio.
- Se identificaron dos errores de calidad de datos como fecha de nacimiento inválida y estado de curso incorrecto, y una brecha en el ETL como sk_tiempo no cargado, los cuales fueron corregidos o documentados como mejoras necesarias.
- La solución permite responder las cuatro preguntas de negocio asignadas y aporta el Índice de Permanencia por Cohorte (IPC) como indicador adicional de valor estratégico.

Recomendaciones

- Implementar un programa de detección temprana de riesgo académico en las primeras cuatro semanas del semestre, enfocado en estudiantes de primer ingreso con matrícula en modalidad virtual y horario nocturno.
- Revisar la estrategia de enseñanza y los recursos de apoyo de la modalidad virtual, especialmente en cursos técnicos como Bases de Datos I, donde la combinación de contenido complejo y modalidad remota nocturna genera los peores resultados.
- Expandir la oferta en modalidad híbrida para horarios de tarde, dado que este esquema muestra el mejor balance de aprobación, nota promedio y retención en los datos disponibles.
- Incorporar datos históricos de múltiples períodos al Data Warehouse para habilitar análisis de cohorte longitudinal y detectar patrones de deserción a lo largo de la trayectoria académica completa del estudiante.

- Corregir el flujo ETL de NiFi para incluir la carga de sk_tiempo y agregar validaciones de tipos de dato como los CAST explícitos en los JOINs TEXT-INT para garantizar la integridad del proceso de carga incremental.

Referencias

Crickard, P. (2019). Data Engineering with Python. Knovel. https://appknovel.tec.elogim.com/kn/resources/kpDEP00022/toc

What is Apache Avro? (s. f.). *IBM*. https://www.ibm.com/think/topics/avro

Živković, M. (2026, 9 de febrero). What is Metabase and how does it work? Embeddable. https://embeddable.com/blog/what-is-metabase